

FICHA DEL PROYECTO

Búsqueda de Empleo Sin Experiencia

¿Qué factores ayudan a un joven sin experiencia a conseguir su primer empleo en Colombia?

Asignatura	Minería de Datos
Docente	Paola Andrea Ortiz
Integrantes	Bryan Samuel Vélez Velásquez Jhon Jairo Melo Largo
Fecha	Septiembre de 2026
Versión	2 — ajustada a los datos obtenidos en el Corte 1

1. Objetivo del proyecto

Pregunta de decisión: ¿Qué características de los jóvenes de 18 a 28 años **sin experiencia laboral** (edad, sexo, nivel educativo, si estudian actualmente y ciudad o departamento donde viven) están asociadas con una mayor probabilidad de conseguir empleo en Colombia, y cómo se relacionan con la demanda de vacantes de su departamento (porcentaje de vacantes que no exigen experiencia y nivel educativo requerido), para decidir **qué formación recomendarles y hacia qué sectores y regiones orientarlos?**

¿Quién toma la decisión? El coordinador de orientación laboral / egresados de la universidad y los orientadores de los centros de empleo del Servicio Público de Empleo (SPE).

¿Qué acción concreta se tomaría? Recomendar la formación (técnica, tecnológica o universitaria) con mayor probabilidad de inserción; priorizar en la orientación los sectores donde más se emplean los jóvenes recién insertados y los departamentos con mayor proporción de vacantes sin experiencia; y ajustar las rutas de orientación (hoja de vida, cursos cortos, prácticas).

¿Se puede responder con datos? Sí. Las dos fuentes ya están descargadas, limpias y cruzadas en el repositorio: la GEIH 2025 del DANE (85.422 registros de jóvenes de 18 a 28 años en la fuerza de trabajo) y el Anexo Estadístico de Demanda Laboral del SPE (vacantes de 2023, el último año publicado).

2. Alcance

Este proyecto analiza los **microdatos de la GEIH 2025 del DANE** (enero-diciembre) para la **población de 18 a 28 años en la fuerza de trabajo** que no tiene experiencia o tiene muy poca, en el total nacional, por departamento y por las 32 ciudades y áreas metropolitanas principales; y las **vacantes registradas en el Servicio Público de Empleo en 2023** (enero-noviembre), agregadas por departamento, municipio, sector, nivel educativo y experiencia requerida. Incluye zonas urbanas y rurales, según la cobertura de la GEIH.

NO cubre a personas mayores de 28 años o con experiencia laboral consolidada; a los jóvenes inactivos (que no trabajan ni buscan empleo); el emprendimiento como alternativa al empleo; las ofertas publicadas solo en portales privados (Computrabajo, LinkedIn, elempleo); la relación entre un joven y una vacante específica (el SPE solo publica totales, no una fila por vacante); ni la calidad o permanencia del empleo a largo plazo.

Tipo de análisis:

- **Descriptivo:** perfil de los jóvenes sin experiencia y tasa de inserción ponderada según nivel educativo, sexo, edad y ciudad; sectores donde trabajan los jóvenes recién insertados (GEIH) frente a los sectores con más vacantes (SPE); y, por departamento, porcentaje de vacantes que no exigen experiencia y nivel educativo que piden.

- **Predictivo básico:** regresión logística y árbol de decisión que estiman la probabilidad de que un joven sin experiencia esté empleado, usando solo variables que existen para ambos grupos (edad, sexo, nivel educativo, si estudia, zona, ciudad o departamento e indicadores del SPE de su departamento). El sector, el contrato y el ingreso **no** entran al modelo porque solo existen para quienes ya tienen empleo.

Definición de “sin experiencia” y variable objetivo

La GEIH no pregunta directamente si un empleo es el primero, así que se aproxima con dos grupos:

Grupo	Definición en la GEIH	Valor de consi guio_empleo	Registros
Recién insertado	Ocupado con 12 meses o menos en su empleo actual (P6426)	1	37.441
Aspirante	Desocupado que nunca ha trabajado (P7430 = No)	0	4.344

Total: 41.785 registros de jóvenes sin experiencia. Las clases están desbalanceadas (90 % / 10 %). El grupo 1 puede incluir jóvenes que tuvieron empleos antes del actual, por lo que el modelo compara “recién empleado” con “nunca empleado”; esta limitación se reporta en las conclusiones.

3. Hipótesis

Hipótesis principal: creemos que el **nivel y tipo de formación (técnica o tecnológica)** está relacionado con una mayor probabilidad de que un joven sin experiencia consiga empleo, **porque** muchas vacantes de nivel de entrada valoran más una formación práctica (por ejemplo, del SENA) que un título universitario, mientras que los profesionales recién graduados compiten por vacantes que suelen exigir uno o más años de experiencia.

Cómo se contrasta: tasa de inserción ponderada por nivel educativo y peso de esa variable en el modelo; en el SPE, relación entre el porcentaje de vacantes que piden formación técnica o tecnológica y el porcentaje que no exige experiencia en cada departamento.

Hipótesis de sector (descriptiva): los jóvenes recién insertados se concentran en comercio, servicios (alojamiento y comida, atención al cliente) y logística, igual que las vacantes de nivel de entrada. Se contrasta comparando la distribución por sector de los recién insertados (GEIH) con la de las vacantes del SPE (hoja *Sectores*). El SPE no cruza sector con experiencia requerida, así que no permite saber directamente qué sectores aceptan más personas sin experiencia.

Hipótesis secundaria: la ciudad de residencia influye, porque las ciudades con más vacantes por joven ofrecen más oportunidades de entrada. Se contrasta comparando la tasa de inserción de cada ciudad con las vacantes registradas en su municipio capital por cada 1.000 jóvenes en la fuerza de trabajo (hoja *Municipios* del SPE).

4. Indicadores de éxito

Indicador	Meta medible
Factores del joven	Identificar al menos 3 características (por ejemplo, nivel educativo, edad, ciudad) con diferencias de al menos 5 puntos porcentuales en la tasa de inserción ponderada entre sus categorías.
Perfiles de jóvenes	Encontrar al menos 3 perfiles (segmentos) de jóvenes con tasas de inserción claramente distintas entre sí.
Modelo predictivo	Lograr un $AUC \geq 0,70$ en datos de prueba y superar al modelo base. Como las clases están desbalanceadas, reportar además precisión y sensibilidad (recall) de la clase 0 (aspirantes).
Sectores de entrada	Identificar al menos 3 sectores con mayor participación de jóvenes recién insertados y compararlos con su participación en las vacantes del SPE.
Cruce de fuentes	Unir GEIH y SPE por código DIVIPOLA de departamento en al menos el 95 % de los registros (logrado en el Corte 1: 100 %, 33 de 33 departamentos) y por municipio capital en las 32 ciudades.
Utilidad para la decisión	Entregar mínimo 3 recomendaciones concretas que un orientador laboral pueda aplicar (qué formación, qué sector, qué ciudad o departamento).

Sabremos que encontramos algo útil (y no solo un número curioso) si los resultados cambian una recomendación real de orientación laboral y se mantienen al compararlos entre ciudades.

5. Fuentes de datos

Fuente 1 — Gran Encuesta Integrada de Hogares (GEIH) 2025, DANE

- **Qué es:** encuesta oficial del mercado laboral en Colombia. Dice, persona por persona, si está ocupada o desocupada, si ha trabajado antes, cuánto tiempo lleva en su empleo, su nivel educativo, edad, sexo, ciudad y sector. Se usan 4 módulos por mes (Características generales, Fuerza de trabajo, Ocupados y No ocupados).
- **Dónde se consigue:** Archivo Nacional de Datos del DANE — microdatos.dane.gov.co (catálogo 853, GEIH 2025).
- **En el repositorio:** `data/raw/geih_2025/` (CSV originales) y `data/processed/geih2025_jovenes_18_28.csv` (limpia).
- **Complemento:** boletín trimestral “Mercado laboral de la juventud” del DANE, para validar las cifras agregadas.

Fuente 2 — Anexo Estadístico de Demanda Laboral del Servicio Público de Empleo (SPE)

- **Qué es:** vacantes registradas en el SPE por año y mes, de 2015 a 2023. Cada hoja cruza el departamento con una sola variable: **Experiencia** requerida, nivel de **Educación**, **Sectores** (CIIU Rev. 4), **Municipios**, Ocupaciones y Salarios. No hay

una fila por vacante.

- **Año usado:** 2023 (enero–noviembre), el más reciente publicado. Es distinto al de la GEIH (2025): se asume que la estructura de la demanda por departamento cambia poco en dos años y se reporta como limitación.
- **Dónde se consigue:** serviciodeempleo.gov.co → DATAEMPLO → Demanda laboral → Anexo estadístico de demanda laboral.

Cruce de las fuentes

- **Por departamento:** `pd.merge` por código DIVIPOLA (relación muchos a uno: jóvenes → departamento). 85.422 filas antes y después; 33 de 33 departamentos con pareja.
- **Por ciudad:** cada una de las 32 ciudades de la GEIH con las vacantes de su municipio capital (32 de 32).
- **Por sector:** comparación agregada; cada sección CIIU del SPE se asigna al mismo grupo de sectores de la GEIH.

6. Riesgos

Riesgo	Cómo lo manejaremos
“Sin experiencia” no es una variable directa en la GEIH; el grupo de recién insertados puede incluir jóvenes con empleos anteriores.	Definición documentada (sección 2) y revisada con la profesora; reportar la limitación al interpretar el modelo.
Clases desbalanceadas (90 % empleados, 10 % aspirantes): un modelo que siempre dice “empleado” acierta el 90 %.	Evaluar con AUC y recall de la clase 0, no solo exactitud; probar pesos de clase balanceados.
Fuga de información: sector, contrato e ingreso solo existen para quienes ya tienen empleo.	Excluir esas variables del modelo y usarlas solo en el análisis descriptivo.
El SPE solo publica totales por departamento o municipio, de 2023, y solo incluye las vacantes que las empresas registran.	Tratar la relación con la demanda como tendencia por región (no causal ni individual) y compararla con los boletines del DANE.
La GEIH es una muestra y usa factores de expansión; sin ellos las proporciones quedan mal calculadas.	Usar los factores de expansión en todos los cálculos descriptivos.
Tiempo del semestre y coordinación entre dos integrantes.	Repartir tareas por fuente, ejecutar los notebooks en orden y hacer commits frecuentes en GitHub.

7. Repositorio del proyecto en GitHub

Nombre del repositorio: Busqueda-Empleo

Link del repositorio: <https://github.com/samuelvelez1003/Busqueda-Empleo>

Estructura actual:

```
Busqueda-Empleo/
├── data/
│   ├── raw/geih_2025/      # Fuente 1: CSV del DANE, 4 módulos por mes
│   ├── raw/spe/           # Fuente 2: Anexo de Demanda Laboral del SPE
│   ├── processed/         # Datos limpios, cruzados y resúmenes
│   └── diccionario/       # Diccionario GEIH y del dataset cruzado
├── notebooks/
│   ├── 01_exploracion.ipynb
│   ├── 02_limpieza.ipynb
│   └── 03_adquisicion_cruce.ipynb
├── docs/                  # Esta ficha
└── README.md
```

Los notebooks se ejecutan en orden desde la carpeta notebooks/, en VS Code, Jupyter o Google Colab (en Colab, la primera celda clona el repositorio con los datos).

Autoevaluación antes de entregar

- ☒ El objetivo tiene forma de pregunta de decisión, no de tema.
- ☒ La pregunta solo pide lo que las fuentes descargadas permiten responder.
- ☒ El alcance dice claramente qué NO cubre el proyecto.
- ☒ La variable objetivo está definida y sus limitaciones están documentadas.
- ☒ La hipótesis explica el “por qué”, no solo el “qué”, y dice cómo se va a contrastar.
- ☒ Los indicadores de éxito son medibles.
- ☒ Hay 2 fuentes de datos identificadas, descargadas y cruzadas, con el año real de cada una.
- ☒ Anotamos riesgos reales, no genéricos.
- ☒ El repositorio existe, tiene README con el objetivo y las carpetas /data y /notebooks.